

# Testowanie hipotez i estymacja w sytuacji populacji skończonej rozmiaru

Kinga Kurowska  
promotor dr inż. Andrzej Giniewicz

Wydział Matematyki  
Politechnika Wrocławska

Wrocław, 01.12.2016r.

# Spis treści

- 1 Motywacja
- 2 Testowanie hipotez - teoria
- 3 Populacja nieskończonego rozmiaru - losowanie ze zwracaniem
  - Model - schemat Bernoulliego
- 4 Populacja skończonego rozmiaru - losowanie bez zwracania
  - Model - rozkład hipergometryczny
  - Sformułowanie statystyki
  - Z Test
  - E Test
- 5 Porównanie testów
- 6 Co jeszcze?
- 7 Bibliografia

# Motywacja

# Motywacja

- znamy wzory w przypadku nieskończonej populacji - rozkład Bernoulliego,

# Motywacja

- znamy wzory w przypadku nieskończonej populacji - rozkład Bernoulliego,
- gdy badana populacja jest faktycznie duża to one się sprawdzają,

# Motywacja

- znamy wzory w przypadku nieskończonej populacji - rozkład Bernoulliego,
- gdy badana populacja jest faktycznie duża to one się sprawdzają,
- jednak gdy badanie populacji wpływa na kolejne wyniki potrzebne jest założenie o skończonej populacji,

# Motywacja

- znamy wzory w przypadku nieskończonej populacji - rozkład Bernoulliego,
- gdy badana populacja jest faktycznie duża to one się sprawdzają,
- jednak gdy badanie populacji wpływa na kolejne wyniki potrzebne jest założenie o skończonej populacji,
- zastosowanie w medycynie.

# Testowanie hipotez - teoria



# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),

# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),
- $H_1$  - hipoteza alternatywna,

# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),
- $H_1$  - hipoteza alternatywna,
- $\alpha$  - poziom istotności testu, czyli prawdopodobieństwo odrzucenia hipotezy zerowej, gdy jest prawdziwa,

# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),
- $H_1$  - hipoteza alternatywna,
- $\alpha$  - poziom istotności testu, czyli prawdopodobieństwo odrzucenia hipotezy zerowej, gdy jest prawdziwa,
- błąd I rodzaju - odrzucenie  $H_0$ , gdy jest prawdziwa,

# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),
- $H_1$  - hipoteza alternatywna,
- $\alpha$  - poziom istotności testu, czyli prawdopodobieństwo odrzucenia hipotezy zerowej, gdy jest prawdziwa,
- błąd I rodzaju - odrzucenie  $H_0$ , gdy jest prawdziwa,
- $p$  wartość - najmniejszy poziom istotności testu, przy którym odrzucamy  $H_0$ ,

# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),
- $H_1$  - hipoteza alternatywna,
- $\alpha$  - poziom istotności testu, czyli prawdopodobieństwo odrzucenia hipotezy zerowej, gdy jest prawdziwa,
- błąd I rodzaju - odrzucenie  $H_0$ , gdy jest prawdziwa,
- $p$  wartość - najmniejszy poziom istotności testu, przy którym odrzucamy  $H_0$ ,
- błąd II rodzaju - nie odrzucenie  $H_0$ , gdy jest fałszywa, dla zadanej alternatywnej wartości badanego parametru,

# Testowanie hipotez - teoria

- $H_0$  - hipoteza zerowa (jej prawdziwość testujemy),
- $H_1$  - hipoteza alternatywna,
- $\alpha$  - poziom istotności testu, czyli prawdopodobieństwo odrzucenia hipotezy zerowej, gdy jest prawdziwa,
- błąd I rodzaju - odrzucenie  $H_0$ , gdy jest prawdziwa,
- $p$  wartość - najmniejszy poziom istotności testu, przy którym odrzucamy  $H_0$ ,
- błąd II rodzaju - nie odrzucenie  $H_0$ , gdy jest fałszywa, dla zadanej alternatywnej wartości badanego parametru,
- moc testu - prawdopodobieństwo odrzucenia  $H_0$ , gdy jest fałszywa, dla zadanej alternatywnej wartości badanego parametru;  
 $p\text{-stwo błędu II rodzaju} = 1 - \text{moc testu}$ .

# Populacja nieskończonego rozmiaru - losowanie ze zwracaniem

Kiedy populację nazywamy nieskończoną?



# Populacja nieskończonego rozmiaru - losowanie ze zwracaniem

Kiedy populację nazywamy nieskończoną?

- Gdy jest na tyle duża, aby uznać, że przebadanie jednego osobnika z populacji nie wpływa znacząco na kolejne wyniki - "zwracamy" go do populacji i losujemy ponownie.

# Populacja nieskończonego rozmiaru - losowanie ze zwracaniem

Kiedy populację nazywamy nieskończoną?

- Gdy jest na tyle duża, aby uznać, że przebadanie jednego osobnika z populacji nie wpływa znacząco na kolejne wyniki - "zwracamy" go do populacji i losujemy ponownie.
- Przykładem może być: populacja kobiet na świecie, albo populacja rzutu kostką.

# Model - schemat Bernoulliego

Gdy losujemy ze zwracaniem najprostszym modelem jest schemat Bernoulliego. Zmienna losowa  $X \sim B(n, p)$ , gdzie  $n$  to liczba prób,  $p$  prawdopodobieństwo sukcesu oraz

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots$$

W języku statystyki  $n$  to wielkość próbki, a  $p$  to prawdopodobieństwo, że zachodzi dana cecha.

# Populacja skończonego rozmiaru - losowanie bez zwracania

Kiedy populację nazywamy skończoną?

# Populacja skończonego rozmiaru - losowanie bez zwracania

Kiedy populację nazywamy skończoną?

- Gdy jest na tyle mała, aby uznać, że przebadanie jednego osobnika z populacji wpływa znacząco na kolejne wyniki - losujemy bez zwracania go do populacji.

# Populacja skończonego rozmiaru - losowanie bez zwracania

Kiedy populację nazywamy skończoną?

- Gdy jest na tyle mała, aby uznać, że przebadanie jednego osobnika z populacji wpływa znacząco na kolejne wyniki - losujemy bez zwracania go do populacji.
- Przykładem może być populacja osób chore na rzadką chorobę.

## Model - rozkład hipergometryczny

Gdy losujemy bez zwracania musimy uwzględnić to, że prawdopodobieństwo sukcesu zmienia się. Rozkładem odpowiadającym takiej sytuacji jest rozkład hipergeometryczny [1].

Zmienna losowa pochodzi z rozkładu hipergeometrycznego, gdy  $X \sim H(n, M, N)$ , gdzie  $n$  to ilość próbek,  $M$  ilość osobników w populacji z daną cechą, a  $N$  ilość całej populacji oraz funkcja prawdopodobieństwa

$$(1) \quad h(k; n, M, N) = P(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, \quad L \leq k \leq U,$$

gdzie  $L = \max\{0, M - N + n\}$ ,  $U = \min\{n, M\}$ .

# Sformułowanie statystyki

Niech  $X_1, X_2$  niezależne zmienne losowe z rozkładu hipergeometrycznego  $X_i \sim H(n_i, M_i, N_i)$ ,  $P(X_i = k_i)$  oraz  $p_i = M_i/N_i$ ,  $i = 1, 2$ .

Postawmy hipotezę  $H_0: p_1 = p_2$  vs.  $H_1: p_1 \neq p_2$ .

Rozważmy statystykę

$$(2) \quad Z_{X_1, X_2} = \frac{X_1/n_1 - X_2/n_2}{\sqrt{V_{X_1, X_2}}},$$

gdzie  $V_{X_1, X_2}$  jest estymatorem wariancji zmiennej losowej  $X_1/n_1 - X_2/n_2$  pod warunkiem  $H_0$  dana wzorem

$$(3) \quad V_{X_1, X_2} = \left( \frac{N_1 - n_1}{n_1(N_1 - 1)} + \frac{N_2 - n_2}{n_2(N_2 - 1)} \right) \left( \frac{X_1 + X_2}{n_1 + n_2} \right) \left( 1 - \frac{X_1 + X_2}{n_1 + n_2} \right). \quad [1]$$



# Z Test

Z Centralnego Twierdzenia Granicznego statystyka  $Z_{X_1, X_2}$  pod warunkiem  $H_0$  jest w przybliżeniu z rozkładu standardowego normalnego  $N(0, 1)$ . Z test odrzuca  $H_0$ , gdy  $p$  wartość

$$P(|Z_{X_1, X_2}| \geq |Z_{k_1, k_2}| | H_0) = 2(1 - \Phi(|Z_{k_1, k_2}|)) \quad [1]$$

jest mniejsza niż poziom istotności  $\alpha$ .

# E Test

E test odrzuca  $H_0$ , gdy  $p$  wartość

$$P(|Z_{X_1, X_2}| \geq |Z_{k_1, k_2}| | H_0) = \sum_{x_1=L_{x_1}}^{U_{x_1}} \sum_{x_2=L_{x_2}}^{U_{x_2}} h(x_1; n_1, \hat{M}_1, N_1) h(x_2; n_2, \hat{M}_2, N_2) \mathbb{1}(|Z_{x_1, x_2}| \geq |Z_{k_1, k_2}|), \quad [1]$$

jest mniejsza niż poziom istotności  $\alpha$ .

Przy czym  $\hat{M}_i = [N_i \hat{p}]$ ,  $\hat{p} = (k_1 + k_2)/(n_1 + n_2)$ ,  
 $L_{x_i} = \max\{0, \hat{M}_i - N_i + n_i\}$ ,  $U_{x_i} = \min\{n_i, \hat{M}_i\}$ ,  $i = 1, 2$ .

# Porównanie testów

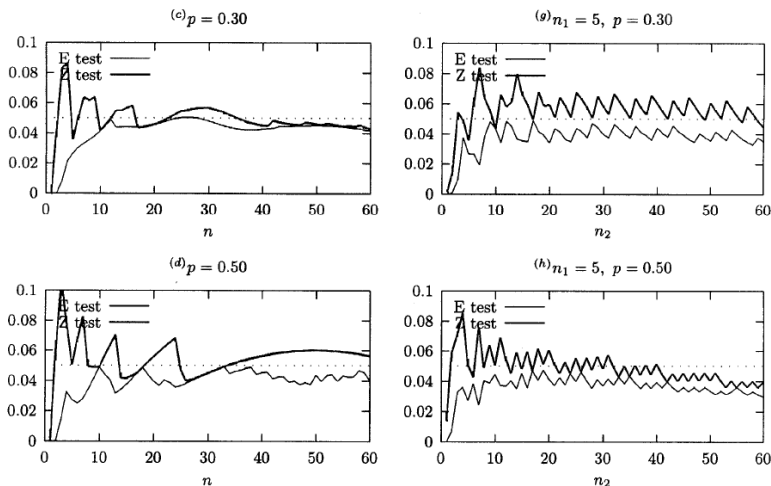


Figure 1. Exact Size of the Tests as a Function of the Sample Sizes at the Nominal Level  $\alpha = 0.05$ ;  $N_1 = N_2 = 100$ .

# Porównanie testów

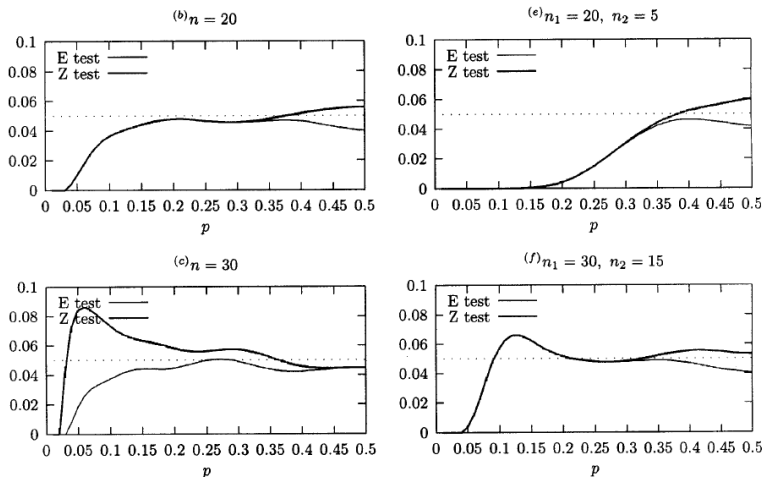


Figure 2. Exact Size of the Tests as a Function of  $p = M_1/N_1 = M_2/N_2$  at the Nominal Level  $\alpha = 0.05$ ;  $N_1 = N_2 = 100$ .

# Co jeszcze?



# Bibliografia



K. Krishnamoorthy, J. Thomson „Hypothesis Testing about Proportions in Two Finite Populations” The American Statistician, Vol. 56, No. 3 (2002): 215-222



J. P. Buonaccorsi, „A Note on Confidence Intervals for Proportions in Finite Populations”. The American Statistician, Vol. 41, No. 3 (1987): 215-218



F. Y. Edgeworth „On the Value of a Mean as Calculated from a Sample” Journal of the Royal Statistical Society, Vol. 81, No. 4 (Jul., 1918), pp. 624-632